

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

Національний Київський Авіаційний Інститут
Факультет комп'ютерних наук та технологій
Аналітика даних та штучний інтелект

Курсова робота

«Гradientні методи оптимізації для навчання нейромережі»

Дисципліна: «Методи оптимізації та дослідження операцій»

Виконав: студент групи

Б-122-23-1-ШІ

Шапран Олег

Перевірив:

Валерій Григорович Хребет

Київ – 2026

1. Зміст

1. Зміст	2
2. Вступ	1
3. Теоретична частина	3
3.1. Нейронні мережі та функція втрат	3
3.2. Градієнтний спуск (GD / SGD)	4
3.3. Метод найшвидшого спуску	5
3.4. Метод Ньютона	6
3.5. Порівняльна характеристика методів	7
4. Практична частина	8
4.1. Постановка задачі	8
4.2. Реалізація трьох методів оптимізації	9
4.3. Експерименти та графіки збіжності	10
4.4. Аналіз результатів	11
5. Висновки	12
6. Список літератури	13

2. Вступ

Актуальність теми:

У сучасних умовах стрімкого розвитку штучного інтелекту та машинного навчання методи оптимізації відіграють ключову роль у навчанні нейронних мереж. Градієнтний спуск та його модифікації залишаються основними алгоритмами навчання нейромереж, оскільки дозволяють ефективно мінімізувати функцію втрат у високорозмірних просторах параметрів.

Однак класичний градієнтний спуск має низку недоліків: повільну збіжність у ярах, чутливість до вибору кроку навчання та можливість застрягання в локальних мінімумах. Метод найшвидшого спуску (steepest descent) намагається подолати проблему вибору кроку за рахунок точної лінійної оптимізації на кожній ітерації, а метод Ньютона використовує квадратичне наближення функції втрат через матрицю Гессе, що теоретично забезпечує квадратичну швидкість збіжності.

Порівняльний аналіз цих методів на конкретній задачі (класифікація XOR простою багатошаровою перцептроном) є актуальним, оскільки дозволяє на практиці оцінити їхню ефективність, обчислювальну складність та придатність для задач нейромережевого навчання.

Мета роботи:

Метою курсової роботи є порівняльний аналіз ефективності трьох градієнтних методів оптимізації — градієнтного спуску з фіксованим кроком, методу найшвидшого спуску та методу Ньютона — при навчанні багатошарового перцептрона на задачі мінімізації функції втрат (XOR).

Завдання роботи:

Для досягнення поставленої мети необхідно вирішити такі завдання:

1. Реалізувати багатошаровий перцептрон (MLP) архітектури $2 \rightarrow 4 \rightarrow 1$ з сигмоїдною активацією та функцією втрат MSE.
2. Реалізувати алгоритми трьох методів оптимізації: градієнтний спуск, метод найшвидшого спуску та метод Ньютона.
3. Провести серію чисельних експериментів з різними початковими умовами та параметрами (кількість ітерацій, точність, час виконання).
4. Виконати порівняльний аналіз результатів за критеріями: швидкість збіжності, кінцеве значення функції втрат, кількість ітерацій, обчислювальна складність та стабільність.

Об'єкт та предмет дослідження

- Об'єкт дослідження — процес навчання нейронної мережі шляхом мінімізації функції втрат.
- Предмет дослідження — градієнтні методи оптимізації (градієнтний спуск, метод найшвидшого спуску, метод Ньютона) у контексті навчання багат шарового перцептрона.

3. Теоретична частина

3.1. Нейронні мережі та функція втрат

Багатошаровий перцептрон (MLP) є одним з найпростіших типів штучних нейронних мереж. У даній роботі використовується MLP архітектури $2 \rightarrow 4 \rightarrow 1$ з сигмоїдною функцією активації у всіх шарах.

Для кожного нейрона обчислення мають вигляд:

$$Z = W \cdot X + b$$

$$A = \sigma(Z) = \frac{1}{1 + e^{-Z}}$$

Функція втрат обрана як Mean Squared Error (MSE):

$$L(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

де $\mathbf{w}$ — вектор усіх параметрів мережі (ваги та зміщення), n — кількість прикладів (у нашому випадку $n=4$ для XOR).

Мета навчання — знайти такі параметри $\mathbf{w}^*$, що мінімізують функцію втрат:

$$\mathbf{w}^* = \arg \min_{\mathbf{w}} L(\mathbf{w})$$

3.2. Градієнтний спуск (GD / SGD)

Градiєнтний спуск — найпоширенiший метод оптимiзацiї в машинному навчаннi. Iдея полягає в iтеративному оновленнi параметрiв у напрямку антиградiєнта функцiї втрат:

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta \nabla L(\mathbf{w}_k)$$

де η — крок навчання (learning rate), ∇L — градiєнт функцiї втрат.

У нашiй реалiзацiї градiєнт обчислюється за допомогою зворотного поширення помилки (backpropagation).

Переваги: простота реалiзацiї, низька обчислювальна складнiсть на iтерацiю.

Недолiки: чутливiсть до вибору η , повiльна збiжнiсть у довгих вузьких ярах, можливе застрягання в локальних мiнiмумах.

3.3. Метод найшвидшого спуску

Метод найшвидшого спуску є модифікацією градієнтного спуску, в якій на кожній ітерації крок η обирається оптимально шляхом розв'язання задачі одновимірної оптимізації:

$$\eta_k = \arg \min_{\eta > 0} L(\mathbf{w}_k - \eta \nabla L(\mathbf{w}_k))$$

Для знаходження оптимального η зазвичай використовують методи одновимірного пошуку (наприклад, золотий переріз, дихотомію або квадратичну інтерполяцію).

Перевага: автоматичний вибір оптимального розміру кроку на кожній ітерації, що часто прискорює збіжність порівняно зі звичайним GD.

Недолік: значно вища обчислювальна вартість (потрібно багаторазово обчислювати функцію втрат на кожній ітерації).

3.4. Метод Ньютона

Метод Ньютона використовує квадратичне наближення функції втрат за допомогою розкладу Тейлора другого порядку:

$$L(\mathbf{w}) \approx L(\mathbf{w}_k) + \nabla L(\mathbf{w}_k)^T (\mathbf{w} - \mathbf{w}_k) + \frac{1}{2} (\mathbf{w} - \mathbf{w}_k)^T H(\mathbf{w}_k) (\mathbf{w} - \mathbf{w}_k)$$

Оновлення параметрів відбувається за формулою:

$$\mathbf{w}_{k+1} = \mathbf{w}_k - H^{-1}(\mathbf{w}_k) \nabla L(\mathbf{w}_k)$$

де H — матриця Гессе (матриця других похідних).

Переваги: квадратична швидкість збіжності поблизу мінімуму, не потребує ручного налаштування кроку.

Недоліки: висока обчислювальна складність (обчислення та обертання матриці Гессе розміром 17×17 у нашому випадку), можлива нестабільність, якщо Гессе не є додатно визначеною.

У нашій реалізації ми будемо використовувати точну матрицю Гессе, оскільки розмірність задачі мала (17 параметрів).

3.5. Порівняльна характеристика методів

Характеристика	Гرادієнтний спуск	Метод найшвидшого спуску	Метод Ньютона
Швидкість збіжності	Лінійна	Суперіорна лінійна	Квадратична
Обчислення на ітерацію	Низьке	Середнє/високе	Високе
Потреба в налаштуванні η	Так	Ні	Ні
Пам'ять	$O(d)$	$O(d)$	$O(d^2)$
Стабільність	Висока	Висока	Середня
Придатність для великих мереж	Відмінна	Добра	Погана

де d — кількість параметрів (у нашій задачі $d = 17$).

4. Практична частина

4.1. Постановка задачі

Об'єктом дослідження є задача навчання багат шарового перцептрона на класичному нелінійному датасеті XOR.

Датасет:

- Вхідні дані X — матриця розміром (4×2) , що містить усі можливі комбінації двох бінарних ознак:

$$X = \begin{bmatrix} 0 & 0 \\ 0 & 1 \\ 1 & 0 \\ 1 & 1 \end{bmatrix}$$

- Цільові значення y — вектор-стовпець (4×1) :

$$y = \begin{bmatrix} 0 \\ 1 \\ 1 \\ 0 \end{bmatrix}$$

Архітектура нейронної мережі:

- Вхідний шар: 2 нейрони
- Прихований шар: 4 нейрони з сигмоїдною активацією
- Вихідний шар: 1 нейрон з сигмоїдною активацією

Загальна кількість параметрів, що підлягають оптимізації: 17 (8 ваг першого шару + 4 зміщення + 4 ваги другого шару + 1 зміщення).

Функція втрат: середньоквадратична помилка (MSE)

$$L(\mathbf{w}) = \frac{1}{4} \sum_{i=1}^4 (y_i - \hat{y}_i)^2$$

Початкове значення функції втрат (при seed=42) становить 0.2557.

4.2. Реалізація трьох методів оптимізації

Базова реалізація багат шарового перцептрона виконана у файлі `neural_network.py`.

Клас MLP містить:

- Ініціалізацію ваг (`_init_`)
- Прямий прохід (`forward`)
- Обчислення функції втрат (`loss`)
- Зворотне поширення помилки (`backward`) — повертає градієнти `dW1`, `db1`, `dW2`, `db2`
- Методи для роботи з параметрами як з вектором: `get_params()` та `set_params()` (необхідні для методу Ньютона)

Реалізовані методи оптимізації:

1. Градієнтний спуск з фіксованим кроком (GD)

- На кожній ітерації: $w = w - \eta \cdot \nabla L(w)$
- Параметр: learning rate η (буде підбиратися експериментально)

2. Метод найшвидшого спуску (Steepest Descent)

- На кожній ітерації виконується точна (або наближена) одномірна оптимізація для знаходження найкращого η :

$$\eta_k = \arg \min_{\eta} L(\mathbf{w}_k - \eta \nabla L(\mathbf{w}_k))$$

- Для пошуку η буде використовуватися метод золотого перерізу або квадратична інтерполяція.

3. Метод Ньютона

- Оновлення: $w = w - H^{-1} \cdot \nabla L(w)$
- Матриця Гессе H (17×17) буде обчислюватися чисельно (за допомогою кінцевих різниць) або аналітично (другий порядок `backpropagation` — складніше, але точніше).

Для стабільності буде використовуватися регуляризація Гессе (додавання малого значення до діагоналі при необхідності).

Метод повертатиме історію втрат, кількість ітерацій та час виконання.

4.3. Експерименти та графіки збіжності

План проведення експериментів:

- Експеримент 1. Вплив learning rate на градієнтний спуск ($\eta = 0.1, 0.5, 1.0, 2.0$)
- Експеримент 2. Порівняння трьох методів при однакових початкових умовах (seed=42)
- Експеримент 3. Порівняння при різних початкових ініціалізаціях (5–10 запусків)

Критерії оцінки:

- Кількість ітерацій до досягнення $\text{tol} = 1\text{e-}6$
- Фінальне значення функції втрат
- Час виконання (секунди)
- Поведінка кривої збіжності (графіки loss vs iteration)

Для візуалізації будуть побудовані графіки:


- Криві збіжності для кожного методу на одному полотні
- Логарифмічна шкала для функції втрат
- Таблиця порівняльних результатів

4.4. Аналіз результатів

test_optimizers.py

Метод	Ітерацій	Час (с)	Loss
Гرادієнтний спуск	2000	0.091	5.22e-03
Метод найшвидшого спуску	200	0.143	5.89e-02
Метод Ньютона	28	0.855	6.42e-07

run_experiments.py



Аналіз по кожному методу:

Градiєнтний спуск: застряг у локальному мінімумі, не добіг до $\text{tol}=1\text{e-}6$ за 2000 ітерацій

Метод найшвидшого спуску: кращий loss ніж GD, але line search дорогий → повільніший за годинником попри менше ітерацій

Метод Ньютона: 28 ітерацій і loss на 4 порядки кращий — квадратична збіжність в дії

5. Висновки

6. Список літератури

- [1] Wikipedia contributors, «Lights Out (game) — Light chasing». 2025.